인수인계서 2단계: 모델과 과제 사양

Nov 7, 2026 · @L

PoC는 정확한 우도 월드 모델 M0와 RSSM-VAE M1을 두 실험에서 정면 비교한다. 실험 1은 고리 vs 가우시안 밴딧으로 목적함수의 간극이 선택을 기울이는지 보고, 실험 2는 MiniGrid-Memory에서 먼저 고정 데이터로 월드 모델만 비교하고(2a), 이어서 같은 계획기를 붙여 비교한다. 이론 전제와 표기는 인수인계서 1단계: 정확한 우도 월드모델 기반 자유에너지 에이전트 PoC 를 따른다.

범위와 전제

비교는 하나다. 나머지 조건은 모두 같게 두고 **다음 관측의 밀도를 만드는 방식만** 바꾼다. M0는 조건부 정규화 흐름, M1은 확률적 잠재와 디코더다.

- **보여 줄 것:** 실험 1의 선택 편향, F 분해표, 샘플 산점도. 실험 2의 성공률 곡선, 월드 모델 지표(예측 로그우도, k스텝 예측 정확도), 실제 프레임과 상상한 프레임의 비교 영상
- **주장하지 않을 것:** 성공률 우위. 비길 수 있고, 그러면 그대로 보고한다. 효과가 보이는 쪽으로 과제를 바꾸지 않는다

용어를 하나 고정한다. 이 문서에서 **흐름**은 정규화 흐름(normalizing flow)이다. 미분 가능하고 역함수가 있는 변환으로 기저분포를 관측 분포로 바꾸며, 변수 변환 공식으로 밀도를 정확히 계산한다. 1단계 문서의 "가역 인터페이스"가 이것이다.

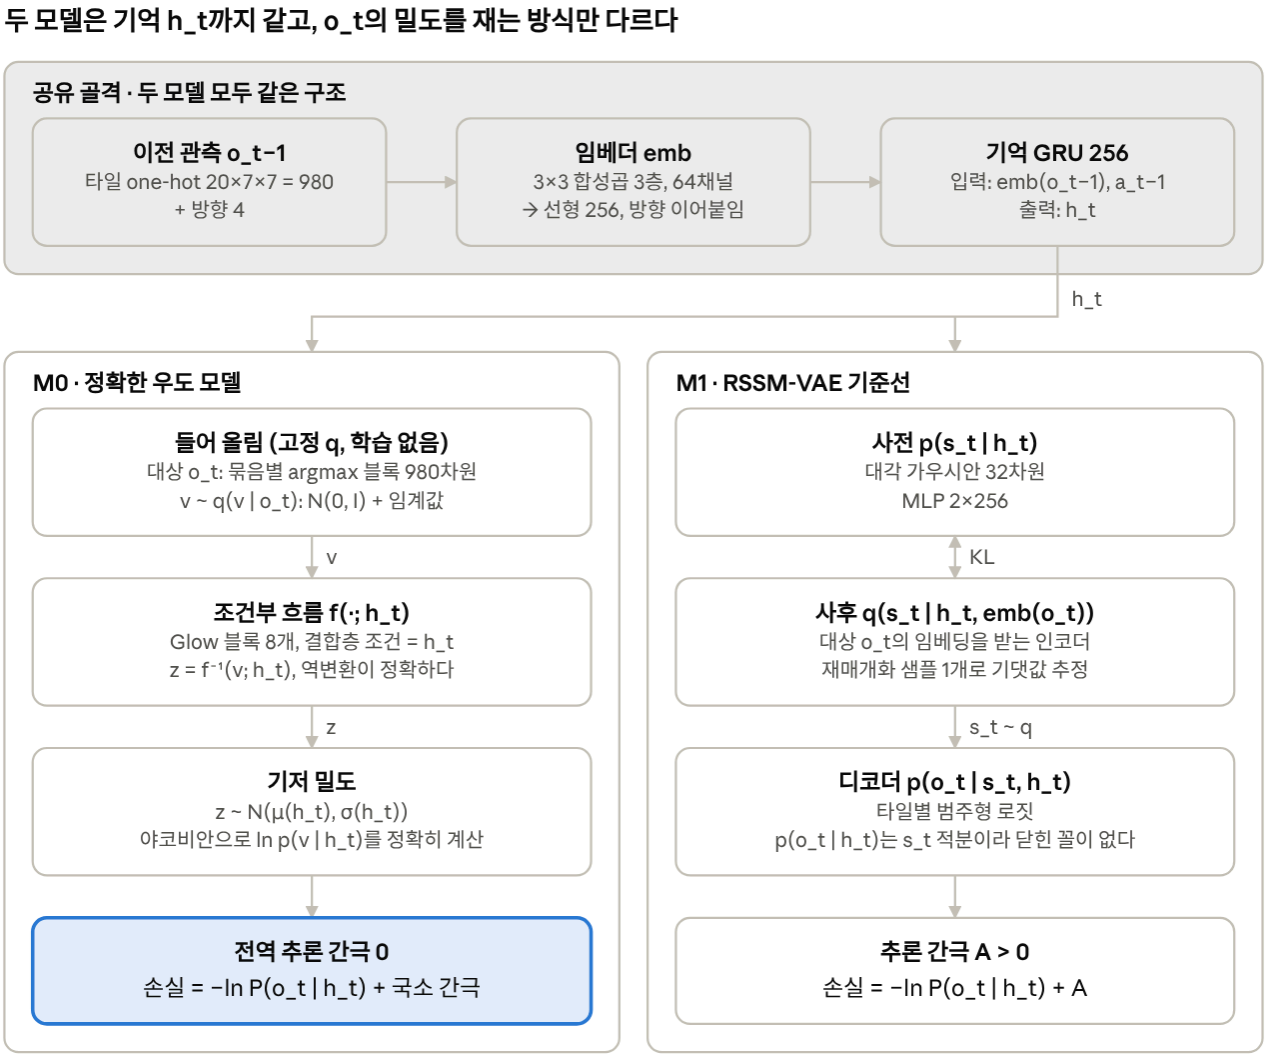
1단계에서 가져오는 전제는 세 가지다.

1. F = A + 𝒥 분해 (2절)
2. G의 정의와 정보 이득 항등식. 계획은 G로 한다 (5절)
3. 탈양자화 간극의 성격 (4절). 이 실험은 argmax 들어 올림을 쓰고, 그때 남는 국소 간극을 감수한다

이전 판에서 바뀐 점은 다섯 가지다.

항목	이전 판	이번 판
과제	E0~E3 (해석 밴딧, 학습 밴딧, Mountain Car, noisy TV)	실험 1: 고리 vs 가우시안 밴딧. 실험 2: MiniGrid-Memory 표준 설정
관측	연속값, 탈양자화 없음	이산 원-핫 + argmax 들어 올림 (Hoogeboom et al. 2021)
흐름	h와 무관한 고정 좌표 변환	h를 조건으로 받는 조건부 흐름
앙상블 (M0-E)	E3에서 사용	보류
계산	CPU 규모를 목표로 함	GPU. 계산 비용은 감수하고 보고한다

한눈에: 두 모델의 데이터 흐름



M0와 M1의 데이터 흐름 · 한 시점

두 모델은 같은 임베더와 GRU로 h_t를 만든다. 그 위에서 M0는 o_t를 연속 공간에 들어 올린 뒤 조건부 흐름으로 되돌려 밀도를 계산하고, M1은 잠재 s_t를 거쳐 ELBO로 근사한다. 그래서 M0의 손실은 놀람에 범주 영역 안의 국소 간극만 더한 값이고, M1의 손실은 놀람에 추론 간극 A를 더한 값이다. 방향과 결과의 범주형 머리는 두 모델에 같이 있어 그림에서 내렸다.

확정된 설계 결정

아래 결정은 논의를 거쳐 확정했다. 바꾸려면 이 표를 먼저 고친다.

ID	결정	이유
D1	M0의 흐름은 기억 h를 조건으로 받는다	무조건부 흐름에 조건부 가우시안 기저를 붙이면 예측 분포의 표현력이 제한된다. M1의 예측 분포는 가우시안의 연속 혼합이라 더 유연하다. 표현력 차이가 결과를 오염시키지 않게 맞춘다. 둘 다 정확한 우도다
D2	기억에는 원래 관측(임베더 출력)을 넣는다	단순하고 두 모델이 같은 코드를 쓸 수 있다. 흐름의 z(예측 대비 정규화된 오차)를 넣는 것은 선택지로 남긴다
D3	앙상블은 보류한다	범위를 줄인다. 그래서 인식적 항의 잡음 취약성에 대한 해법은 이번 범위에 없다
D4	이산 격자는 속성 묶음별 argmax로 연속 공간에 들어 올린다. 들어 올림 분포 q(v | x)는 학습하지 않는 고정 분포다 (N(0, I) + 임계값 변환). 데이터에서 추정한 통계는 쓰지 않는다	흐름은 입력 스케일에 민감하다. 에이전트의 행동에 따라 데이터 분포가 바뀌므로 데이터 통계는 안정적이지 않다
D6	과제는 둘이다. 실험 1은 고리 vs 가우시안 밴딧, 실험 2는 MiniGrid-Memory 표준 설정이다	실험 1은 메커니즘을 가장 작은 형태로 분리해 보이고, 실험 2는 작고 표준적인 RL 과제에서 결과를 보인다. 효과가 보이도록 과제를 변형하지 않는다
D7	탈양자화 간극은 감수한다	간극은 같은 범주 영역 안에서 v가 어디 있느냐에 대한 것이다. 영역이 무한히 뻗어 있어 닫힌 상한이 없으므로 측정해서 보고한다. argmax 영역들이 공간 전체를 나누므로 유효하지 않은 원-핫으로 새는 질량은 없다
D8	GPU를 쓴다. 계산 비용은 감수한다	M0는 압축 없이 약 1,000차원을 다루므로 M1보다 무겁다. 기본 설정에서 프레임당 순전파는 M0 약 52 MFLOP, M1 약 22 MFLOP(약 2.4배)이고, 파라미터는 약 266만과 277만으로 비슷하다. 파라미터 수와 학습 시간을 함께 보고한다

D5(밴딧 설정)는 실험 1 절에서 정한다.

실험 1: 고리 vs 가우시안 밴딧

목적함수에 추론 간극이 있느냐 없느냐가 선택을 기울이는지를, 기억과 계획기 없이 가장 작은 형태로 보인다. 2차원이라 GPU에서 시드당 몇 분이면 끝나고, 결과가 산점도로 바로 보인다. 실험 2보다 먼저 끝낸다.

과제

항목	설정
선택지	두 개. 하나를 고르면 2차원 관측 하나가 나온다
고리	반지름 $r \sim N(1, 0.1^2)$, 각도 $\theta \sim U[0, 2\pi)$. 관측 = $r(\cos\theta, \sin\theta)$
가우시안	$N(0, \sigma^2 I)$, $\sigma = 0.388854$
엔트로피	둘 다 $H = 0.9492$ nats. 고리의 미분 엔트로피에 맞춰 σ를 정했다
기대	실제 놀람이 같으므로, 놀람을 정확히 아는 에이전트는 두 선택지를 같은 확률로 고른다

모델

모델	구조	목적함수
M0	조건부 RealNVP. 결합층 12개, 결합 신경망 MLP 2층 × 128(ELU), 스케일 $2\cdot\tanh(\cdot/2)$, 조건 = 선택지 원-핫, 기저 $N(0, I)$	정확한 $-\ln p(o \mid \text{선택지})$
M1-a	VAE. 잠재 2차원, 사전 $N(0, I)$, 대각 가우시안 q와 가우시안 디코더(각각 MLP 2층 × 128), 디코더 분산 학습	$-$ELBO, $\beta = 1$, 재매개화 샘플 1개
M1-b	M1-a와 같고 디코더 표준편차를 0.1로 고정	위와 같음
M1-a/b × IWAE	M1-a, M1-b 각각을 IWAE 하한으로 학습. $k = 1, 5, 50$	$-\text{IWAE}_k$. $k = 1$이면 $-$ELBO

학습 조건은 모든 모델이 같다. 두 선택지 샘플을 반반 섞은 배치 512, 매 스텝 새 샘플, Adam 학습률 1e-3, 3만 스텝. 목적함수 보정은 없다.

선택 규칙

선택지 a마다 $F_a = E_{o\sim a}[F(o)]$를 계산하고 $P(a) \propto \exp(-F_a)$로 고른다. F는 각 모델이 학습에 쓰는 값이다(M0는 $-\ln p$, M1은 $-$ELBO 또는 $-\text{IWAE}_k$). 자유에너지원리의 "F를 최소화하는 선택"을 그대로 옮긴 규칙이며, 실험 2의 G 계획기와는 다르다.

측정과 산출물

선택지마다 새 샘플 4,000개로 잰다. 시드 5개 이상, 평균과 95% 신뢰구간으로 보고한다.

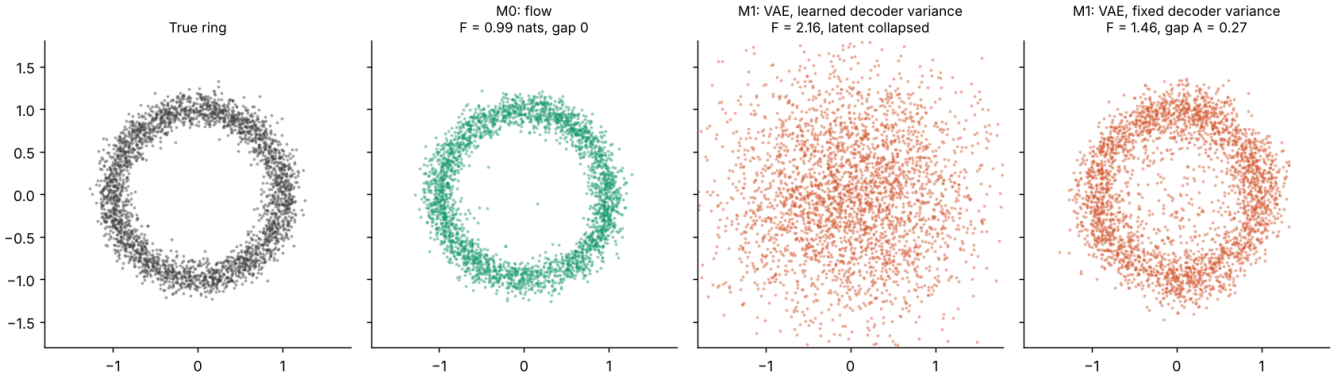
값	정의
F̄	모델이 쓰는 F의 평균
ℑ̂	−ln p(o) 추정. M0는 정확한 값, M1은 IWAE k = 2,000
Â	F̄ − ℑ̂. 추론 간극
B̂	ℑ̂ − H. 모델 불일치
P(고리)	선택 규칙에 따른 고리 선택 확률

- 그림 E1-1: 고리 선택지에서 실제, M0, M1-a, M1-b가 뽑은 샘플 산점도
- 그림 E1-2: IWAE k에 따른 Â_고리 − Â_가우시안과 P(고리). k가 커져 간극이 줄 때 선택 편향도 줄어드는지 보는 용량-반응 그림
- 표 E1: 모델 × 선택지별 F̄ = H + B̂ + Â 분해

예비 실행 결과 (참고용)

CPU에서 JAX로 돌린 예비 결과다. 본 실행은 공통 조건(PyTorch)으로 다시 구현해 재현한다.

모델	시드	F̄ 고리	F̄ 가우시안	Â 고리	Â 가우시안	P(고리)
M0	0, 1, 2	0.99, 0.99, 0.96	0.92, 0.96, 0.96	0	0	0.483, 0.492, 0.499
M1-a	0, 1, 2	2.16, 2.16, 2.16	0.92, 0.95, 0.96	< 0.001	< 0.001	0.224, 0.230, 0.231
M1-b	0	1.46	0.94	0.27	0.02	0.373



- M1-a는 잠재를 쓰지 않고 고리를 가우시안 하나로 근사했다. F̄ 2.16은 고리를 가우시안 하나로 맞췄을 때의 교차 엔트로피 ln(2πe · 0.505) ≈ 2.155와 같다. Â는 0이지만 B̂가 약 1.2 nats다. ELBO 학습이 간극을 없애려고 생성기를 망가뜨린 경우다(1단계 2.3절).
- M1-b는 잠재를 쓰지만 고리가 흐릿하고, 간극이 고리에서만 0.27 nats다. 이 간극이 선택을 직접 기울인다.
- 가우시안 쪽 F̄가 0.949보다 조금 낮은 것은 샘플 4,000개의 표본 오차(표준오차 약 0.016)다.

용량 비교 (예비, 시드 0). M0가 이긴 것이 모델 크기 덕인지 확인하려고 크기를 바꿔 돌려 보았다. 수치는 고리 선택 확률이다.

모델	파라미터	고리 F¯	P(고리)
M0, 결합층 2개	3.5만	1.52	0.35
M0, 결합층 4개	6.9만	1.04	0.47
M0, 결합층 12개	20.7만	0.99	0.48
M1-a, 은닉 128 / 320	3.5만 / 21.1만	2.16 / 2.16	0.22 / 0.23
M1-b, 은닉 128 / 320	3.5만 / 21.1만	1.46 / 1.47 (Â 0.27 / 0.31)	0.37 / 0.38

크기를 맞추면 M0도 치우친다. 차이는 크기를 키울 때 나타난다. M0의 오차는 모델 불일치라 용량을 늘리면 사라지고, M1의 오차는 목적함수에서 나오므로 6배로 키워도 줄지 않는다. 본 실행에서 시드를 늘려 확인할 수 있으면 좋다.

완료 기준

- 시드 5개 이상에서 위 표와 그림 두 장을 만든다.
- M0의 P(고리)가 0.5에서 벗어나면 B̂ 차이로 설명되는지 확인한다.
- IWAE k에 따라 Â 차이와 선택 편향이 같은 방향으로 움직이는지 보고한다. 움직이지 않으면 그대로 보고한다.

실험 2: MiniGrid-Memory

실험 2는 두 부분이다. 2a는 고정 데이터로 월드 모델만 비교한다(계획기 없음, 먼저 한다). 2b는 계획기를 붙인 온라인 실험이고, 2a 결과를 본 뒤 진행 여부를 정한다. 아래 "환경과 관측", "공유 골격", "M0", "M1"은 둘 다에 쓰이고, "계획기"와 학습 루프는 2b에만 쓰인다.

환경과 관측

환경은 `MiniGrid-MemoryS13-v0`를 표준 설정 그대로 쓴다. 에이전트는 작은 방에서 물체를 보고, 좁은 복도를 지나 갈림길 끝의 두 물체 중 같은 것으로 가야 한다. 맞는 물체에 닿으면 성공, 틀린 물체에 닿거나 시간이 다 되면 실패로 끝난다.

항목	설정
행동	왼쪽 회전, 오른쪽 회전, 전진 (3개). 물체에 닿으면 종료되는 과제라 나머지 행동은 쓰지 않는다

항목	설정
격자 관측	자기중심 7×7. 칸마다 (물체, 색, 상태)를 원-핫으로 펼친다 → 20 × 7 × 7 = 980차원 이진값
방향 관측	4범주
결과 관측	진행 / 성공 / 실패, 3범주. 보상은 이 채널로만 들어온다
보상 크기	모델링하지 않는다. 성공 보상은 결과와 스텝 수로 결정되기 때문이다
미션 문자열	쓰지 않는다

격자는 속성 묶음(물체 11, 색 6, 상태 3)마다 argmax로 범주를 정하는 방식으로 연속 공간에 들어 올린다. 연속 공간의 모든 점이 유효한 원-핫 하나에 대응하고, 범주 번호에 순서를 강제하지도 않는다. 방향과 결과는 들어 올리지 않고 범주형 우도로 그대로 다룬다.

소스 코드에서 확인할 것은 세 가지다. 확인한 값을 이 표에 적는다.

- [ ] 범주 수: 물체 11, 색 6, 상태 3인지 (다르면 격자 차원을 고친다)
- [ ] `max_steps` 기본값
- [ ] 성공·실패 판정이 물체에 "닿음"인지, 특정 행동이 필요한지 (행동 3개로 충분한지)

공유 골격

기억을 만드는 부분은 두 모델이 완전히 같은 코드다. 시점은 둘 다 "과거 (o_{<t}, a_{<t})로 o_t를 예측"으로 맞춘다.

$$h_t=\mathrm{GRU}\big(h_{t-1},\ [\,\mathrm{emb}(o_{t-1}),\ \mathrm{onehot}(a_{t-1})\,]\big),\qquad h_0=0$$

모듈	입력 → 출력	구조
격자 임베더 emb	원-핫 격자 20×7×7 (들어 올리기 전) + 방향 4 → 256	3×3 conv 3층, 64채널, ELU → 펼침 → 선형 256. 방향은 펼친 뒤 이어 붙인다
기억	[emb, 행동 원-핫 3], h_{t−1} → h_t	GRU, 256

o_0는 h_0 = 0에서 예측한다. 즉 초기 관측의 분포도 학습한다.

모델은 아래 인터페이스를 구현한다. 계획기와 학습 루프는 이 인터페이스만 부른다.

```
class WorldModel:
    def init_state(self, batch) -> State
    def observe(self, state, a_prev, o_t) -> (State, F_t)      # 실제 관측으로
갱신 + 스텝별 F
    def imagine(self, state, a) -> (State, o_hat, logp)        # 상상 롤아웃 한
스텝
    def info_gain(self, state, a, o_hat) -> IG                 # 모델마다 정의가
다름
    def loss(self, obs_seq, act_seq) -> sum_t F_t
```

믿음 상태는 M0가 h 하나, M1이 (h, s)다.

M0: 조건부 흐름 모델

M0는 다음 관측의 밀도를 h_t를 조건으로 받는 흐름으로 직접 만든다. 숨은 상태에 대한 잠재가 없으므로 전역 추론 간극은 0이다. 이산 격자를 연속 공간에 들어 올리는 데서 생기는 국소 간극만 남는다.

$$F_t=-\ln P(\text{방향}_t\mid h_t)-\ln P(\text{결과}_t\mid h_t)-\Big[\ln p_z\big(f^{-1}(v_t;h_t)\mid h_t\big)+\ln\Big|\det\frac{\partial f^{-1}}{\partial v}\Big|-\ln q(v_t\mid x_t)\Big],\qquad v_t\sim q(\cdot\mid x_t)$$

대괄호 부분은 샘플 하나의 v_t ~ q(· | x_t)로 계산한 이산 격자 로그우도의 하한(ELBO)이다. 참값과의 차이는 KL[q(v | x_t) ‖ p(v | x_t, h_t)]이고, 이것이 M0에 남는 유일한 간극이다.

모듈	구조
들어 올림 q(v | x)	Hoogeboom et al.(2021)의 임계값 방식. 속성 묶음마다 u ~ N(0, I)를 뽑아 정답 범주 성분은 T = u_x로 그대로 두고, 나머지는 v_i = T − softplus(T − u_i)로 T 아래로 내린다. ln q(v | x) = ln N(u; 0, I) − Σ_{i≠x} ln sigmoid(u_x − u_i). 학습하는 파라미터는 없다
흐름 본체	Glow형 블록 4개. 블록 = ActNorm → 가역 1×1 conv(20채널) → affine coupling. 7×7은 홀수 크기라 다중 스케일(squeeze)은 쓰지 않는다. 단계 2에서 로그우도가 수렴하지 않으면 8개로 늘리고, 늘린 사실을 보고한다
coupling 마스크	채널 분할(10/10)과 체커보드 마스크를 블록마다 번갈아 쓴다 (각각 2번씩)
coupling 신경망	3×3 conv ResNet 1블록, 64채널, ELU. 입력에 조건 채널 16개를 붙인다. 조건 채널 = 선형(h_t)를 7×7로 펼친 것이고, 이 선형층은 모든 블록이 공유한다. 스케일은 tanh로 제한한다

모듈	구조
기저분포	N(μ(h_t), σ(h_t)). MLP 2층 × 256이 980차원 평균과 로그 표준편차를 출력한다
보조 헤드	MLP 2층 × 256(h_t) → 방향 4범주, 결과 3범주

상상 롤아웃. z ~ p_z(· | h)를 뽑고 v = f(z; h)를 계산한다. 칸마다 물체·색·상태 묶음별로 argmax를 취하면 언제나 유효한 원-핫 x̂가 나온다. 방향과 결과는 범주분포에서 뽑는다. 기억에는 이 x̂를 넣는다. 실제 관측과 같은 형식을 유지하기 위해서다.

오차 채널 선택지(D2). 기억에 원래 관측 대신 z_t = f^{-1}(v_t; h_t)를 넣는 변형을 설정 플래그로 둔다. 실제 관측에서는 v_t ~ q(· | x_t)를 쓴다. 기본값은 끄기다.

M1: RSSM-VAE

M1은 가우시안 잠재를 쓰는 순차 VAE다. 사전분포, 사후분포, 디코더의 구성은 PlaNet/Dreamer v1의 RSSM과 같고, 기억의 입력만 공유 골격을 따른다. 디코더는 이산 관측에 대한 정확한 범주형 우도이고, 대신 잠재에 대한 추론 간극이 있다. 두 모델은 결국 같은 이산 로그우도의 하한을 최적화하고, 간극의 성격만 다르다. M0는 범주 영역 안의 위치에 대한 국소 간극, M1은 숨은 상태에 대한 간극이다.

$$F_t=-\mathbb E_{q(s_t\mid h_t,e_t)}\ln p(o_t\mid s_t,h_t)+D_{KL}\big[q(s_t\mid h_t,e_t)\,\|\,p(s_t\mid h_t)\big],\qquad e_t=\mathrm{emb}(o_t)$$

모듈	구조
확률적 잠재 s	32차원 대각 가우시안
사전분포 p(s_t | h_t)	MLP 2층 × 256 → 평균, 로그 표준편차
사후분포 q(s_t | h_t, e_t)	e_t는 공유 골격의 같은 임베더 출력. MLP 2층 × 256
디코더	[s_t, h_t] → 선형 → 7×7×64 → 3×3 conv 2층 → 칸마다 물체·색·상태 범주형 로짓. 방향과 결과는 별도의 MLP 헤드로 범주형
기대값 추정	재매개화 샘플 1개
보정	KL 균형과 free nats를 쓰지 않는다 (β = 1). 학습이 불안정해서 쓰게 되면 반드시 보고한다

디코더는 (s_t, h_t)가 주어지면 칸들이 서로 독립인 범주형이다. 칸 사이의 의존성은 잠재 s가 담는다. M0는 흐름이 칸 사이의 의존성을 직접 모델링한다.

기억의 입력. 표준 RSSM은 기억에 잠재 s_{t−1}을 넣는다. 이 비교에서는 "다음 관측의 밀도를 만드는 방식만 다르다"는 원칙을 지키기 위해 M0와 같이 관측 임베딩 emb(o_{t−1})을 넣는다. 표준 RSSM 입력(s_{t−1}, 또는 둘 다)은 설정 플래그로 둔다.

상상 롤아웃. $s \sim p(s \mid h)$를 뽑고, 디코더의 범주분포에서 칸마다 샘플링해 $\hat{x}$를 만든다. 방향과 결과도 범주분포에서 뽑는다. 다음 기억 갱신에는 M0와 똑같이 $\hat{x}$를 임베더에 넣는다.

실험 2a: 고정 데이터 월드 모델 비교

계획기 없이, 정해진 정책으로 모은 데이터로 두 모델을 학습하고 보류 집합에서 비교한다. 계획기 설정, 정보 이득의 크기, 에이전트의 배회가 결과에 섞이지 않으므로 목적함수와 모델의 차이만 보인다. 실험 2b보다 먼저 한다.

데이터

집합	구성	용도
학습용	스크립트 정책에 확률 0.2로 무작위 행동을 섞은 에피소드 500개 + 무작위 정책 에피소드 500개	학습
보류	무작위 정책 50개 + 스크립트 정책 50개 (공통 조건의 데이터 분할과 같음)	평가

두 집합은 서로 다른 환경 시드로 모으고, 한 번 모아 모든 모델과 시드가 같은 파일을 쓴다. 스크립트 정책은 시작 방의 물체가 보일 때까지 뒤돌아본 뒤 갈림길로 가서 같은 물체 쪽으로 도는 정책이다(무작위 행동이 없으면 10~15스텝). 매 스텝 현재 상태에서 다시 계획하므로 무작위 행동이 섞여도 대부분 성공하고, 갈림길에서 무작위 행동이 나오면 실패 사례도 생긴다. 무작위 에피소드는 길어서(평균 약 390스텝, 최대 845스텝) 넓은 상태 범위를 덮는다.

학습

- 공통 조건 표를 따른다(Adam 3e-4, 기울기 클리핑 100, 시드 5개).
- 갱신 50,000회, 배치 32, 시퀀스 길이 32.
- 조각 뽑기: 에피소드를 길이와 무관하게 균등하게 고른 뒤, 그 안에서 시작점을 균등하게 고른다. 짧은 스크립트 에피소드가 긴 무작위 에피소드에 묻히지 않게 하기 위해서다. 에피소드가 32스텝보다 짧으면 처음부터 전체를 쓰고 나머지는 마스크한다.
- 기억은 조각 시작에서 h = 0으로 둔다. 따라서 32스텝보다 먼 기억 의존성은 배우지 못한다. 스크립트 에피소드는 대부분 한 조각에 통째로 들어가므로 "물체를 봄 → 결과" 의존성은 데이터에 들어 있다.

측정

- "측정과 산출물"의 그림 2(월드 모델 지표)와 그림 3(상상 영상)을 이 실험에서 만든다. 갱신 5,000회마다 보류 집합에서 잰다.
- M1의 Â와 M0의 Â_deq를 에피소드 구간(방, 복도, 갈림길)별로 나란히 둔 표를 만든다.
- 비용 표: 파라미터 수, 갱신당 시간.

완료 기준

- 시드 5개 모두에서 보류 집합 로그우도가 수렴한다. M0가 수렴하지 않으면 흐름 블록을 8개로 늘리고 보고한다.
- 1스텝 예측 정확도가 무작위 예측보다 높다.
- 그림 2, 그림 3, 구간별 간극 표, 비용 표를 만든다.

계획기 (실험 2b)

행동은 이산 행동열에 대한 CEM으로 G를 최소화해 고른다. 계획기 코드는 두 모델이 공유하고, 정보 이득 계산만 모델에 위임한다.

```
G(\pi)=\sum_{\tau=t}^{t+H-1}\Big[-\ln C(\text{결과}_\tau)-
\mathrm{IG}_\tau\Big]
```

항목	설정
방식	스텝마다 행동 3개에 대한 범주분포. 엘리트의 행동 빈도로 갱신하고 평활화 0.1을 준다. 매 스텝 재계획해 첫 행동만 실행한다
크기	수평선 H = 20, 후보 1,000, 엘리트 100, 반복 5
롤아웃 종료	결과가 성공 또는 실패로 샘플되면 그 롤아웃은 거기서 끝난다. 이후 항은 더하지 않는다
선호 C	결과 채널에만 건다. ln C = 환경의 표준 보상 r: 성공 1 − 0.9·t/T, 실패 0, 진행 0 (t는 에피소드 스텝, T = max_steps). 보상을 그대로 선호로 쓰는 Fountas et al. (2020)의 방식을 따른다
후보당 샘플	1개 (두 모델 동일)

모델	정보 이득 IG_τ
M0	이산 예측 엔트로피 H[P(x_τ | h_τ)]의 추정치를 쓴다. 흐름에서 v ~ p(v | h_τ)를 뽑아 x̂ = argmax(v)를 만들고, 같은 v로 −ln p(v | h_τ) + ln q(v | x̂)를 계산한다. ln p(v | h_τ)는 샘플링 중 log-det으로 함께 나오고, ln q(v | x̂)는 임계값 변환을 거꾸로 푼 u(u_x = T = v_x, u_i = T − ln(e^{T−v_i} − 1))에서 닫힌 식으로 계산하므로 흐름을 한 번만 통과한다. 기댓값은 H[P(x | h_τ)] − E KL[p(v | x, h_τ) ‖ q(v | x)]로, 이산 엔트로피의 하한이다. p와 q의 비율이라 좌표에 무관하고, 전처리 좌표에서 생기던 상수 오프셋(약 957 nats)이 없다
M1	D_KL[q(s | h, ê) ‖ p(s | h)]. 상상한 관측 x̂를 임베더로 다시 인코딩해 계산한다

두 IG는 정의가 다르다. M0는 관측 수준의 예측 엔트로피이고, M1은 숨은 상태에 대한 정보 이득이다 (1단계 5.3절). 이 차이 자체가 비교 대상의 일부다. 두 IG 모두 계수 1로 더한다. Tschantz et al.(2020), Fountas et al.(2020)과 같은 관례이고, 모델별로 조정하지 않는다.

학습 루프(실험 2b)와 공통 조건

아래 학습 루프는 실험 2b의 것이고 두 모델이 같다. 표의 공통 조건은 실험 2a와 2b 모두에 적용한다.

1. 무작위 정책으로 50 에피소드를 모아 재현 버퍼를 채운다.
2. 계획기로 1 에피소드를 모은다.
3. 재현 버퍼에서 길이 32인 시퀀스를 배치 32로 뽑아 100회 갱신한다. 손실은 Σ_t F_t다.
4. 2~3을 총 500 에피소드까지 반복한다.

항목	규칙
프레임워크	PyTorch (기본값)
최적화	Adam, 학습률 3e-4, 기울기 노름 클리핑 100. 두 모델 동일
시드	5개. 같은 시드 번호는 두 모델에서 같은 환경 난수열을 쓴다
데이터 분할	평가용 보류 에피소드 100개를 따로 모아 둔다. 무작위 정책 50개 + 스크립트 정책 50개. 스크립트 정책은 시작 방의 물체가 보일 때까지 뒤돌아본 뒤 같은 물체 쪽으로 가는 정책이다(실험 2a 데이터 참고). 한 번 모아 모든 모델이 같은 집합으로 평가하고, 학습에는 쓰지 않는다

항목	규칙
파라미터 수	맞추지 않는다. 모델별 파라미터 수, 학습 시간, 계획 시간을 표로 보고한다
목적함수 보정	없음. 학습이 불안정해 보정을 넣으면 반드시 보고한다
설정 변경	어느 한 모델을 위해 바꾼 설정은 다른 모델에도 같이 적용하고 변경 이력을 남긴다

측정과 산출물

산출물은 그림 세 장이다. 그림 2와 그림 3은 실험 2a에서, 그림 1은 실험 2b에서 만든다. 모든 수치는 시드 5개의 평균과 부트스트랩 95% 신뢰구간으로 보고한다.

그림 1. 성능

에피소드별 성공률 곡선(이동 평균 20 에피소드)을 M0와 M1에 대해 같은 축에 그린다. 비길 수 있다.

그림 2. 월드 모델 지표

보류 에피소드 집합에서 학습 진행에 따라 잰다. 실험 2a는 갱신 5,000회마다, 실험 2b는 에피소드 50개마다다.

지표	정의	주의
이산 로그우도	스텝당 ln P(o_t | o_{<t}, a_{<t}) 추정치(nats). M0는 q(v | x)를 제안으로 쓰는 중요도 가중, M1은 q를 제안으로 쓰는 입자 필터. 둘 다 샘플 1,000개	둘 다 참값의 하한을 추정하므로 참 차이를 완전히 보여 주지는 않는다. 샘플 수를 100·1,000으로 바꿔 추정치가 수렴하는지 함께 보고한다
k스텝 예측 정확도	테스트 궁적에서 실제 행동을 넣되 관측은 넣지 않고 k스텝 굴린 뒤, 예측 격자와 실제 격자의 칸 단위 일치율. k = 1, 5, 10	예측 격자는 상상 롤아웃과 같은 방식으로 만든다 (샘플이 아니라 최빈값 기준으로도 함께 잔다)
M1의 간극	Â = F − ℐ. 상태별로 기록해 에피소드 구간(방, 복도, 갈림길)별로 집계한다	참 간극의 하한이다. 행동 차이를 해석하는 근거로 쓴다
M0의 간극	Â_deq = F − ℐ. M1의 Â와 같은 방식으로 상태별로 기록하고 같은 구간별로 집계한다	닫힌 상한이 없으므로 측정값으로 보고한다. Â와 나란히 두면 모델 족과 무관하게 목적함수의 차이만 비교할 수 있다

그림 3. 상상 영상

보류 에피소드 몇 개를 골라, 같은 시작점에서 세 패널을 나란히 둔다. 실제 프레임, M0가 상상한 프레임, M1이 상상한 프레임이다. 처음 5스텝은 실제 관측을 넣고, 이후는 실제 행동만 넣어 굴린다. 예측한 기호는 MiniGrid 렌더러로 그려 실제 화면과 같은 모양으로 만든다. 갈림길이 시야에 들어오는 구간을 반드시 포함한다. 두 물체의 좌우 배치가 에피소드마다 무작위라 예측 분포가 두 봉우리가 되는 지점이기 때문이다.

실행 순서와 완료 기준

앞 단계의 완료 기준을 만족하기 전에는 다음 단계로 넘어가지 않는다. 문제가 생겼을 때 원인이 환경, 모델, 계획기 중 어디인지 가리기 위해서다.

실험 1을 먼저 끝낸다. 아래 단계 0~2가 실험 2a, 단계 3~5가 실험 2b다. 2b는 2a 결과를 본 뒤에 진행 여부를 정한다.

단계	할 일	완료 기준
0	환경 래퍼, 원-핫 인코딩, 렌더러, 스크립트 정책. 보류 에피소드 100개와 실험 2a 학습용 데이터셋 1,000개 수집	"환경과 관측"의 확인 항목 3개를 채우고, 스크립트 정책의 성공률이 100%다
1	흐름과 들어 올림 단위 테스트	역변환 오차 < 1e-5. 저차원(2~4차원) 장난감 버전에서 밀도 수치적분이 1 ± 1e-3. 들어 올림: 모든 $v \sim q(\cdot \mid x)$에서 $\text{argmax}(v) = x$이고, $\ln q$의 log-det이 자동미분 야코비안과 일치. 범주 3개짜리 장난감 모델에서 유효한 x 전체에 대한 $P(x)$의 합이 1 ± 1e-2
2	고정 데이터 학습 = 실험 2a	"실험 2a" 절의 완료 기준. 시드 5개, 로그우도 수렴, 그림 2·3, 구간별 간극 표, 비용 표
3	계획기 단독 점검 (2b)	참 환경 시뮬레이터를 모델 대신 넣으면 CEM이 과제를 푼다. 풀지 못하면 수평선과 후보 수를 모델과 무관하게 먼저 조정한다
4	온라인 학습 (2b)	시드 5개 × 두 모델 × 500 에피소드. 측정 지표를 모두 기록한다
5	그림 1과 비용 표 (2b)	파라미터 수, 학습 시간, 계획 시간을 포함한다

단계 3은 계획기 설정이 모델 비교보다 먼저 정해져야 하기 때문에 둔다. 참 시뮬레이터로도 못 푸는 설정이면, 모델 간 차이를 볼 수 없다.

결과가 예상과 다르면 그대로 보고한다. 한 모델에 유리하도록 설정을 바꾸지 않는다.

열린 결정 사항과 보류한 과제

기본값을 정해 두었지만 확정되지 않은 항목이다. 확정하면 체크하고 본문을 고친다.

- [ ] 시드 수: 5개(기본) 또는 10개
- [ ] 실험 2b의 에피소드당 갱신 횟수 100, 총 500 에피소드로 충분한지
- [ ] 선택 플래그를 절제 실험으로 돌릴지: M0 기억에 z 넣기(D2), M1 기억에 표준 RSSM 입력 s 넣기
- [ ] q(u | x)를 학습할지 (기본은 고정 N(0, I)). 학습하면 간극이 줄지만 학습되는 추론기가 생긴다
- [ ] 1단계 문서 5.3절에 "잡음이 어디에 흡수되느냐" 단서를 반영할지
- [ ] 실험 2b(계획기 온라인 실험)를 할지. 2a 결과를 본 뒤 정한다

보류한 과제는 삭제하지 않고 기록만 남긴다. 주 실험 결과를 본 뒤 필요하면 되살린다.

과제	역할	보류한 이유
해석적 밴딧 (선형 가우시안)	추론 간극이 행동을 치우치는 메커니즘을 닫힌 형태로 확인. 선택지 A의 간극 0.8756 nats($\sigma^2 = 0.1$)	표준 RL 과제에 집중하기로 함
Continuous Mountain Car	차이가 없을 것으로 예측되는 대조군	범위 축소
noisy TV + 앙상블 (M0-E)	모호성 항이 없는 대가와 그 해법	앙상블 보류 (D3)